Санкт-Петербургский филиал федерального государственного автономного образовательного учреждения высшего профессионального образования "Национальный исследовательский университет "Высшая школа экономики"

Факультет Санкт-Петербургская школа социальных и гуманитарных наук Национального исследовательского университета «Высшая школа экономики»

Рабочая программа дисциплины

«Программирование для анализа данных и воспроизводимые исследования»

для направлений 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика»

подготовки бакалавра (в рамках майнора «Обработка и анализ данных»)

2 курс (3-4 модуль)			
Авторы программы: Мусабиров И.Л., МА, магистр информатики и вычислительной техники, ilya@musabirov.info Суворова А.В., кандидат физико-математических наук, asuvorova@hse.ru Сироткин А.В., кандидат физико-математических наук, avsirotkin@hse.ru			
Согласована методистом ОСУП	<i>''</i>	>	2016 -
Т.Г. Ефимова	<u>"</u> "	·	_ 20101
Утверждена академическим советом ОП «Социология»	«»	·	_ 2016 г
Академический руководитель ОП Д.А.Александров			
Санкт-Петербург, 2016			

Настоящая программа не может быть использована другими подразделениями университета и другими вузами без разрешения кафедры-разработчика программы.



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

1 Область применения и нормативные ссылки

Настоящая рабочая программа дисциплины устанавливает минимальные требования к знаниям и умениям студента, а также определяет содержание и виды учебных занятий и отчетности.

Программа предназначена для преподавателей, ведущих дисциплину «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных», учебных ассистентов и студентов направлений подготовки бакалавра 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 38.03.02 «Менеджмент», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика», 45.03.01 «Филология», обучающихся по образовательным программам «Государственное и муниципальное управление», «История», «Менеджмент» «Логистика и управление целями поставок», «Политология», «Социология», «Экономика», «Юриспруденция», «Востоковедение и африканистика», «Филология», подготовки бакалавра.

Рабочая программа дисциплины разработана в соответствии с:

- Образовательным стандартом НИУ ВШЭ http://www.hse.ru/standards/standard;
- Образовательными программами «Государственное и муниципальное управление», «История», «Менеджмент» «Логистика и управление целями поставок», «Политология», «Социология», «Экономика», «Юриспруденция», «Востоковедение и африканистика», «Филология» по направлениям подготовки 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 38.03.02 «Менеджмент», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика», 45.03.01 «Филология»;
- Объединенным учебным планом университета по образовательной программе 39.03.01 «Социология», утвержденным в 2016 г.; Учебными планами университета по направлениям подготовки 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 38.03.02 «Менеджмент», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика», 45.03.01 «Филология»

2 Цели освоения дисциплины

Целями освоения дисциплины «Программирование для анализа данных и воспроизводимые исследования» являются изучение особенностей различных методов сбора и агрегации данных, формирование навыков планирования сбора и обработки данных, изучение пакетов ориентированных на обработку специфических данных, в частности, сетей и текстов, знакомство с принципами построения социальных рекомендательных систем.

3 Компетенции обучающегося, формируемые в результате освоения дисциплины

В результате освоения дисциплины студент должен:

- Знать
- о ключевые понятия, цели и задачи использования социальных сетей;
- о методологические основы исследования социальных процессов и социальных общностей;
- о актуальные направления исследований в области анализа социальных сетей
- Уметь
- о визуализировать социальные сети,
- о анализировать свойства, структуру и особенности социальных сетей;
- о выбирать метод анализа, соответствующий исследовательской задаче,
- о интерпретировать полученные результаты;
- Иметь навыки (приобрести опыт) чтения и анализа академической литературы по анализу социальных сетей, использования современного инструментария, применяемого в анализе социальных сетей

Уровни формирования компетенций:

РБ - ресурсная база, в основном теоретические и предметные основы (знания, умения)

СД - способы деятельности, составляющие практическое ядро данной компетенции

МЦ - мотивационно-ценностная составляющая, отражает степень осознания ценности



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

компетенции человеком и готовность ее использовать

В результате освоения дисциплины студент осваивает следующие компетенции:

B pesjiibiaie seb	CIIII		инлины студент осьаивает с	подучение компетен	
Компетенция	Код по ОС ВШЭ	Уровень формирования компентин	Дескрипторы – основные признаки освоения (показатели достижения результата)	Формы и методы обучения, способствующие формированию и развитию компетенции	Форма контроля уровня сформированности компетенции
Способен учиться, приобретать новые знания, умения, в том числе в области, отличной от профессиональной	УК-1	РБ	Способен на основе рекомендаций и самостоятельного поиска осваивать новые методы анализа данных	Практические и самостоятельные занятия по написанию программ для сбора и обработки информации	Контрольная работа Домашние задания Экзамен
Способен вести исследовательскую деятельность, включая анализ проблем, постановку целей и задач, выделение объекта и предмета исследования, выбор способа и методов исследования, а также оценку его качества	УК-6	РБ	Способен выделять постановки задач для решения с использованием различных методов анализа данных, осознанно выбирать методы и инструментальные средства	Самостоятельная деятельность по анализу результатов проведенных исследований	Контрольная работа Домашние задания Экзамен
Способен работать с информацией: находить, оценивать и использовать информацию из различных источников, необходимую для решения научных и профессиональных задач (в том числе на основе системного подхода)	УК-5	РБ	Владеет навыками написания программ для автоматизированного сбора и анализа информации из различных источников в глобальных компьютерных сетях	Практические занятия, программный проект	Контрольная работа Домашние задания Экзамен

4 Место дисциплины в структуре образовательной программы

Настоящая дисциплина относится к блоку дисциплин дополнительного профиля (майнора) «Обработка и анализ данных», обеспечивающих бакалаврскую подготовку.

Основные положения дисциплины должны быть использованы в дальнейшем при изучении следующих дисциплин майнора.

5 Тематический план учебной дисциплины

ОБЪЕМ ДИСЦИПЛИНЫ - 5 зачетных единиц

Ī				Ayı	циторные	часы	Самостоя
	№	Название раздела	Всего часов	Лек- ции	Семи-	Практи- ческие занятия	Самостоя- тельная работа





Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

1	Введение в социально-сетевой анализ и социальные	16	4	8	20
	рекомендательные системы				
2	Анализ и визуализация сетей в R. Социальные сети	44	2	8	20
	в бизнесе, экономике, обществе				
3	Введение в анализ текста в рекомендательных си-	28	2	10	20
	стемах				
4	Проектная организация цифровых исследований	102	0	10	86
ИТО	ΓΟ	190	8	36	146

6 Формы контроля знаний студентов

Тип контроля	Форма контроля	1 год				Параметры		
_		1	2	3	4			
Текущий	Контрольная работа			**		письменные работы 80 минут		
	Домашнее задание			*	*	Прохождение онлайн-упражнений и тестов		
	Программный проект				*	Сдача письменного отчета по финальному проекту Защита проекта и ответов на дополнительные вопросы по применяемым методам		
Итоговый	Экзамен				*	Письменный экзамен 80 минут		

7 Критерии оценки знаний, навыков

Критерии оценки отчета и презентаций программного проекта

В проекте предусмотрены этапы выполнения, соблюдение дедлайнов которых влияет на итоговую оценку.

Конкретное расписание проекта, включая этапы выполнения и дедлайны, объявляется студентам в начале работы по проекту.

При оценивании проекта проверяется выполнение требований конкретных заданий (требований к отчёту).

Внимание при оценке уделяется следующим критериям, пропорционально влияющими на оценку.

- корректность применения методов агрегации и анализа данных (сетей, текстов), написанного программного кода
- ориентированность на заказчика
- качество и целостность выдвинутой системы гипотез
- хорошо структурированная организация и содержательная наполненность отчета
- использование навыков оформления графического материала, полученного в ходе обучения на настоящем курсе, корректность применения визуализаций и таблиц

Проект, исходный код которого (в виде RMarkdown), не собирается корректно из-за ошибок не может получить оценку выше 5 (удовлетворительно).

Критерии оценки прохождения тестов

Одной из форм проверки усвоения теоретических навыков являются тесты на онлайн-платформе Stepik (stepik.org). Их прохождение играет формативную роль: количество попыток не ограничивается. Итоговая оценка за тесты: зачтено/ не зачтено. Оценка "зачтено" ставится при прохождении суммарно более 50% заданий в установленные и отображаемые на онлайн-платформе дедлайны, без ограничения числа попыток. При получении оценки "зачтено", в формулу накопленной оценки выставляется 10, при получении оценки "не зачтено" -- 0.



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

Критерии заданий, включающих элементы анализа данных (в составе домашних и контрольных работ)

- корректность применения методик анализа (в рамках знаний, полученных в курсе, смежных дисциплинах, домашнем чтении) и интерпретации результатов;
- эффективное использование языковых средств и структур данных, методов преобразования и агрегации данных в организации потока анализа данных, их ввода и вывода, в том числе освоенных в рамках предыдущих тем и курсов в рамках майнора.

Критерии оценки контрольной работы

Количество баллов за задания контрольной работы указывается в образовательном окружении. Учитывая большой разброс знаний студентов, в контрольную работу могут быть включены задания повышенной сложности, выполнение которых не обязательно для получения оценки 10.

8 Содержание дисциплины

Раздел 1. Введение в социально-сетевой анализ и социальные рекомендательные системы Основные понятия сетевого анализа. Меры центральности. Модели формирования и эволюции сетей. Алгоритмы Community Detection. Сильные и слабые связи. Рекомендательные системы. Социальные рекомендательные системы.

Литература по разделу

- 1. Easley D., Kleinberg J. Networks, crowds, and markets: Reasoning about a highly connected world. Cambridge University Press, 2010.
- 2. Barabasi A. L. Network Science. Cambridge University Press, 2016. URL: http://barabasi.com/book/network-science
- 3. Adamic L. A., Glance N. The political blogosphere and the 2004 US election: divided they blog //Proceedings of the 3rd international workshop on Link discovery. ACM, 2005. P. 36-43.
- 4. Dunbar R. I. M. The social brain: mind, language, and society in evolutionary perspective //Annual Review of Anthropology. 2003. P. 163-181.
- 5. Newman M., Barabasi A. L., Watts D. J. The structure and dynamics of networks. Princeton University Press, 2006.
- 6. Кабаков Р.И. R в действии. Анализ и визуализация данных на языке R / Р.И. Кабаков; пер. П. Волкова. ДМК Пресс, 2014. 580 р.
- 7. James, Gareth, Daniela Witten, Trevor Hastie, and Robert Tibshirani. An Introduction to Statistical Learning: With Applications in R (Springer Texts in Statistics). 2013 edition. Springer, 2013.

Раздел 2. Анализ и визуализация сетей в R. Социальные сети в бизнесе, экономике и обществе Пакет igraph. Создание графов. Импорт данных. Визуализация графов. Меры центральности в igraph. Алгоритмы выделения сообществ. Социальный капитал. Примеры сетей (сети организаций, сети аффилиаций, сети дружбы, сети финансовых отношений, сети политических связей)

Литература по разделу

- 1. Easley, David, and Jon Kleinberg. 2010. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. 1 edition. New York: Cambridge University Press.
- 2. Luke, Douglas. 2015. A User's Guide to Network Analysis in R. Use R! Cham: Springer International Publishing.
- 3. Beenen, Gerard, Kimberly Ling, Xiaoqing Wang, Klarissa Chang, Dan Frankowski, Paul Resnick, and Robert E. Kraut. 2004. "Using Social Psychology to Motivate Contributions to Online Communities." In *Proceedings of the 2004 ACM Conference on Computer Supported Cooperative Work*, 212–21. CSCW '04. New York, NY, USA: ACM. doi:10.1145/1031607.1031642.



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

- 4. Karau, Steven J., and Kipling D. Williams. 1993. "Social Loafing: A Meta-Analytic Review and Theoretical Integration." *Journal of Personality and Social Psychology* 65 (4): 681–706. doi:10.1037/0022-3514.65.4.681.
- 5. Scardamalia, Marlene, and Carl Bereiter. 1994. "Computer Support for Knowledge-Building Communities." *Journal of the Learning Sciences* 3 (3): 265–83. doi:10.1207/s15327809jls0303_3.
- 6. Luke, Douglas. 2015. A User's Guide to Network Analysis in R. Use R! Cham: Springer International Publishing.
- 7. Kolaczyk E.D. Statistical Analysis of Network Data with R / E.D. Kolaczyk, G. Csárdi. New York: Springer, 2014. 207 p.
- 8. igraph R package. URL: http://igraph.org/r/
- 9. igraph documentation. URL: http://igraph.org/r/doc/igraph.pdf
- 10. Кабаков Р.И. R в действии. Анализ и визуализация данных на языке R / Р.И. Кабаков; пер. П. Волкова. ДМК Пресс, 2014. 580 р.

Раздел 3. Введение в анализ текста в рекомендательных системах

Инфраструктура анализа текста в R. Классические пакеты и новые разработки. Обработка текста. Регулярные выражения. Схожесть текстов. Анализ тональности текста. Тематическое моделирование.

Литература по разделу

- 1. Robinson, Julia Silge and David. 2017. Text Mining with R. http://tidytextmining.com/.
- 2. Grolemund, Garrett, and Hadley Wickham. 2016. R for Data Science. http://r4ds.had.co.nz/.
- 3. Кабаков Р.И. R в действии. Анализ и визуализация данных на языке R / Р.И. Кабаков; пер. П. Волкова. ДМК Пресс, 2014. 580 р.

4. Проектная организация цифровых исследований

- Введение в проектную организацию цифровых исследований. Стадии проекта.
- Выполнение учебного проекта.
- Презентация результатов.

9 Образовательные технологии

Преподавание языковых средств R и концепций сетевого анализа осуществляется с использованием современных абстракций, с упором на понимание на концептуальном уровне и формальным введением по мере необходимости.

Объединяющим методическим компонентом курса является учебный проект, выполняемый группами студентов с применением спектра рассматриваемых в курсе методов. Проект не предполагает жесткого дисциплинарного разделения по ролям. Выполняемый под руководством одного или нескольких старшекурсников, проект задаёт минимальную технологическую планку, делая акцент на поиске дополнительных источников информации, осмысленном выборе методов, обсуждении и интерпретации результатов. При этом технически сложные элементы выполняются при помощи старшекурсников и/или преподавателей. Даже при индивидуальном проекте или использовании внешнего проекта (в рамках НУЛ или НУГ, другой деятельности студента) обсуждение технических приёмов и методов, найденных дополнительных источников данных, обмен информацией со студентами, работающими по смежным темам и реег review составляют существенную часть работы.

9.1 Методические указания студентам по освоению дисциплины

Для обеспечения необходимого уровня уверенного владения инструментальными средствами (языком R и средой RStudio) предусмотрен сквозной компьютерный практикум по всем разделам курса. Кроме того, рабочая среда с веб-доступом позволяет прозрачно переносить работу между практи-



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

кумом и самостоятельной работой студента. Поэтому для успешного освоения дисциплины студент должен пользоваться возможностью самостоятельной работы, дополнительными ресурсами, указанными в программе и на форуме курса. Пользуйтесь возможностью самостоятельной работы! Свои знания по части материалов курса можно проверить, используя онлайн-тесты. Хотя порог их прохождения на оценку достаточно низок, мы советуем вам проходить все тесты и задавать вопросы на форуме.

Учебные ассистенты, преподаватели, ваши однокурсники и старшекурсники часто делятся дополнительными ресурсами на форуме курса. **Пользуйтесь этой возможностью, задавайте и отвечайте на вопросы других.** Помимо возможного бонуса к оценке, это позволяет более глубоко усвоить материал.

Для коммуникации с преподавателями по административным вопросам пользуйтесь почтой курса!

Проект в составе этого курса даёт вам первую возможность сделать что-то сравнительно сложное в новой для вас области. Воспользуйтесь этой возможностью, чтобы углубить свои знания!

9.2 Учебно-методическая литература для самостоятельной работы студентов

- Easley, David, and Jon Kleinberg. 2010. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. 1 edition. New York: Cambridge University Press.
- Grolemund, Garrett, and Hadley Wickham. 2016. *R for Data Science*. http://r4ds.had.co.nz/.
- Robinson, Julia Silge and David. 2017. Text Mining with R. http://tidytextmining.com/.
- Кабаков Р.И. R в действии. Анализ и визуализация данных на языке R / Р.И. Кабаков; пер. П. Волкова. ДМК Пресс, 2014. 580 р.

10 Оценочные средства для текущего контроля и аттестации студента

К средствам текущего контроля относится домашняя работа, контрольная работа и контроль чтения. Задание на чтение состоит в письменном ответе на ряд вопросов по соответствующей главе книги из списка основной литературы. Курс читается на английском языке, поэтому все задания также формулируются на английском языке.

10.1 Вопросы для оценки качества освоения дисциплины

- 1. Проиллюстрируйте концепции «social influence» и «social selection». Почему так важно различать эти понятия?
- 2. В чем заключается принцип «triadic closure» в сетевой теории?
- 3. Как различные метрики центральности помогают в анализе сетей?
- 4. Как анализ тональности текста может помочь в построении рекомендательных систем?
- 5. Что такое тематическое моделирование? Приведите пример использования тематического моделирования.
- 6. В чем заключаются особенности рекомендательной системы, основанной на коллаборативной фильтрации? Фильтрации на основе содержания?
- 7. Как могут работать рекомендательные системы в социальных сетях? Что такое «пузырь фильтров»?

10.2 Пример домашнего задания

Домашнее задание состоит в выполнении тестовых заданий на онлайн-платформе Stepik (stepik.org). Примерные формулировки вопросов:

1) Примените различные метрики центральности к сети персонажей из "Отверженных". Выпишите самых популярных персонажей на основе этих метрик.



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

- 2) Используйте несколько методов выделения сообществ, например, Walktrap, основанный на случайном блуждании по сети. В ответе укажите, сколько сообществ каждый из алгоритмов выделил. Какой, на ваш взгляд, алгоритм сработал лучше и почему?
- 3) Загрузите базу данных по обсуждениям косметических предметов. Добавив словарь с настроениями для английского языка, выясните, какие предметы связаны с положительными отзывами? Какие предметы чаще ругают? Найдите примеры комментариев.

10.3 Пример задания контрольной работы

- 1. Постройте дерево решений, предсказывающее заработную плату работника на основе опросных данных. В ответе укажите переменную, которая внесла наибольший вклад в предсказание на первом шаге построения дерева.
- 2. По данным о испытаниях самых быстрых машин за 1939-2014гг. выберите три самые популярные фирмы (make_nm). Постройте график для сравнения распределений скоростей, максимально развиваемых (top_speed_kph) машинами, выпускаемыми этими фирмами. Опишите полученные результаты.
- 3. В этой части мы повторим основные функции из пакета igraph для анализа сетей. Мы будем работать с сетью персонажей из романа "Отверженные" (Les Miserables) В. Гюго. Связи между персонажами появляются, если они упоминаются в одной главе книге. Вес связи зависит от частоты появления вместе. Подробнее про датасет можно почитать здесь.
- 4. Загрузите сеть с помощью функции read.graph(). Укажите сколько в получившейся сети персонажей и связей между ними.
- 5. Используйте Edge Betweenness иерархический метод, состоящий в последовательном удалении связей в порядке убывания показателя центральности по посредничеству ребер (edge betweenness scores). Определите, сколько персонажей алгоритм отнес к первой группе.
- 6. Извлеките эго-сеть для персонажа Gavroche, чтобы остались только те, кто появлялся с ним в одной главе. Укажите, сколько узлов в получившейся сети.
- 7. Загрузите данные с отзывами к отелям. Используя функции пакета tidytext, удалите стоп-слова и приведите все к нижнему регистру. Оставьте только комментарии с рейтингов равным 5 и постройте облако слов на основе самых частотных слов. Проделайте то же самое для комментариев с рейтингом 3 и меньше.
- 8. Сравните облака слов по этим двум категориям. На что обращают внимание обе категории комментаторов?
- 9. Используя функции из пакета quanteda и проанализируем тематического моделирования по текстам отзывов к отелям. Модель выделила группы слов, которые часто встречаются вместе, мы составили из них "темы" отзывов. Для каждой темы мы знаем топ-20 слов. Опишите различия отелей с разным количеством звезд на уровне тем отзывов.

10.4 Программный проект

Одним из важных моментов при формировании навыков и знаний в рамках майнора "Обработка и анализ данных" является формирование навыков совместной работы над общим проектом. Одним из путей формирования таких навыков могут являться групповые проекты, выполняемые в небольших коллективах из 3-5 студентов разных образовательных программ. Количество студентов, проходящих обучение в рамках майнора, составляет 180-200 человек, что требует формирования большого числа (30-40) сравнимых между собой проектов. Этого можно достичь, сформировав общее для всех групп задание, проанализировать по заданным критериям набор данных, при этом набор данных для каждой группы формируется индивидуально, как фрагмент одного большого набора данных. В качестве такого набора данных используется "Атагоп product data" — база, содержащая 142.8 миллионов обзоров различных товаров, оставленных в период с мая 1996 года по июль 2014. Кроме непосредственно текста обзора, в данных так же содержится оценка товара, оценка полезно-



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01«Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

сти обзора, идентификационный номер пользователя, написавшего обзор, а также описание товара. Такая база позволяет формировать разные по сложности и по содержанию задания на разных этапах курса, в частности, задания по анализу текстов отзывов и их связь с оценкой, анализ сетевой структуры потребителей, выделение "схожих" по оценкам пользователей продуктов, для формирования рекомендаций и другие.

В качестве единого проектного задания в 2016-2017 учебном году используется построение рекомендательной системы на основе этих данных.

11 Порядок формирования оценок по дисциплине

Накопленная оценка по дисциплине рассчитывается с помощью взвешенной суммы оценок за отдельные формы текущего контроля знаний следующим образом:

$$O_{\text{накопленная}} = 0.15 * O_{\text{текуший } 1} + 0.2 \ O_{\text{текуший } 2} + 0.2 \ O_{\text{текуший } 3} + 0.45 \ O_{\text{текуший } 4}$$
, где

 $O_{mekyuuuŭ 1}$ — оценка за контрольную работу 1

Отекущий 2— оценка за контрольную работу 2

 $O_{meкуuuuй}$ 3— оценка за прохождение онлайн-упражнений и тестов

 $O_{mekvuuuŭ}$ 4— оценка за программный проект

Результирующая оценка по дисциплине (которая идет в диплом) рассчитывается следующим образом:

$$O_{\text{резульm}} = 0.8 \cdot O_{\text{накопл}} + 0.2 \cdot O_{\text{экз}}$$
. Где

 $O_{\text{накопл}}$ – накопленная оценка по дисциплине

 O_{9K3} — оценка за экзамен

Способ округления всех оценок: арифметический.

Активность на форуме курса приносит бонус к результирующей оценке до 10%.

12 Учебно-методическое и информационное обеспечение дисциплины

12.1 Основная литература

- Кабаков Р.И. R в действии. Анализ и визуализация данных на языке R / Р.И. Кабаков; пер. П. Волкова. ДМК Пресс, 2014. 580 р.
- Easley, David, and Jon Kleinberg. Networks, Crowds, and Markets: Reasoning About a Highly Connected World. 1 edition. New York: Cambridge University Press. (online version available: www.cs.cornell.edu/home/kleinber/networks-book/)
- Grolemund, Garrett, and Hadley Wickham. 2016. R for Data Science. http://r4ds.had.co.nz/.
- Robinson, Julia Silge and David. 2017. Text Mining with R. http://tidytextmining.com/.

12.2 Дополнительная литература

- Barabási, Albert-László. 2016. Network Science. Cambridge University Press. (online version available: barabasi.com/book/network-science)
- Luke, Douglas. 2015. A User's Guide to Network Analysis in R. Use R! Cham: Springer International Publishing.
- Cioffi-Revilla, Claudio. 2014. Introduction to Computational Social Science: Principles and Applications. 2014 edition. London; New York: Springer.
- Mark EJ Newman. 2010. Networks: An Introduction. 1 edition. Oxford; New York: Oxford University Press.



Рабочая программа дисциплины «Анализ данных и технологии работы с данными» в рамках майнора «Обработка и анализ данных» для направлений: 38.03.02 «Менеджмент» (ОП «Логистика и управление целями поставок», ОП «Менеджмент»), 38.03.04 «Государственное и муниципальное управление», 46.03.01 «История», 41.03.04 «Политология», 39.03.01 «Социология», 38.03.01 «Экономика», 40.03.01 «Юриспруденция», 41.03.03 «Востоковедение и африканистика» подготовки бакалавра

- Kolaczyk E.D. Statistical Analysis of Network Data with R / E.D. Kolaczyk, G. Csárdi. New York: Springer, 2014. 207 p.
- The SAGE Handbook of Social Network Analysis. 2011. London; Thousand Oaks, Calif: SAGE Publications Ltd.
- Robins, Garry L. 2015. Doing Social Network Research: Network-Based Research Design for Social Scientists. SAGE Publications Ltd.
- Kolaczyk E.D. Statistical Analysis of Network Data with R / E.D. Kolaczyk, G. Csárdi. New York: Springer, 2014. 207 p.

12.3 Ресурсы информационно-телекоммуникационной сети «Интернет»

- 1. igraph R package. URL: http://igraph.org/r/
- stepik.org
- 3. datacamp.com
- 4. edx.org

12.4 Программные средства

RStudio. Пакет MS Office/OpenOffice.org

13 Материально-техническое обеспечение дисциплины

Аудитория с проектором для лекций, компьютерные аудитории с современными версиями браузеров согласно требованиям RStudio Server к клиентам. Клиент ssh для консольного доступа к серверу. Сервер для работы студентов (спецификация в зависимости от количества записавшихся на майнор) с Ubuntu Linux, RStudio Server и другими пакетами, в зависимости от специфики проектов.